

Une tâche de classification galactique et ses améliorations possibles.

Classification de galaxies à partir du dataset de Galaxy Zoo

Camille Dussauchoy et Delfin Erçelik (DL3IASO)

Projet final pour le cours d'Applications du Deep Learning

Mardi 19 mai 2026



Plan général

- 1 Introduction et motivation
- 2 Le dataset : constitution et exemples
- 3 Approche Machine Learning
- 4 Architectures des modèles Deep Learning
- 5 Entraînement
- 6 Résultats et évaluation
- 7 Conclusion

Plan

- 1 Introduction et motivation
- 2 Le dataset : constitution et exemples
- 3 Approche Machine Learning
- 4 Architectures des modèles Deep Learning
- 5 Entraînement
- 6 Résultats et évaluation
- 7 Conclusion

Pourquoi classifier des galaxies ?

- En astronomie, les images fournissent des informations riches sur la morphologie des objets célestes.
- Identifier les types de galaxies permet de mieux comprendre la structure et l'évolution de l'univers.
- Tâche rendue nécessaire par la quantité massive de données (ex. mission **DESI**).



Exemple de champ galactique

Objectif du projet

La tâche à proprement parlé

À partir d'un dataset pré-traité issu de *Galaxy Zoo*, il s'agit d'entraîner un modèle capable de **classer efficacement les galaxies** en trois catégories :

Spirale | **Elliptique** | **Incertaine**

Démarche adoptée

- ➊ Constituer et préparer le dataset.
- ➋ Établir une baseline avec des méthodes de *machine learning* classique.
- ➌ Construire et évaluer plusieurs modèles de *deep learning*.
- ➍ Comparer les approches et conclure sur la méthode optimale.

Les types de galaxies étudiés

Spirale (SPIRAL)

Disques aplatis avec bras en spirale, riches en gaz et poussière, formation stellaire active.



Elliptique (ELLIPTICAL)

Formes sphériques ou ellipsoïdales, peu de gaz, population d'étoiles âgées.



Incertaine (UNCERTAIN / PDK)

Classification ambiguë : données insuffisantes, image peu claire ou morphologie perturbée (ex. galaxies en fusion).

Plan

- 1 Introduction et motivation
- 2 Le dataset : constitution et exemples
- 3 Approche Machine Learning
- 4 Architectures des modèles Deep Learning
- 5 Entraînement
- 6 Résultats et évaluation
- 7 Conclusion

Constitution du dataset

Source : Galaxy Zoo 2 [2]

- ~600 000 images disponibles sur le portail Galaxy Zoo.
- Nous avons sélectionné **15 000 images** balancées :

Classe	Nombre d'images	Proportion
Spirale	5 000	33%
Elliptique	5 000	33%
Incertaine	5 000	33%
Total	14 982	(18 erreurs techniques)

Données tabulaires associées

Fichier CSV avec colonnes clés : OBJID, RA, DEC, probabilités PEL, PCW, PACW, PDK...

Exemples d'images du dataset




Galaxie spirale

bras visibles, structure en
disque



Galaxie elliptique

contour lisse, peu de
structure



Galaxie incertaine

image bruitée ou ambiguë

Remarque

Les images sont souvent **bruitées et peu détaillées** : cela constitue la principale difficulté de la tâche.

Pré-traitement

- Correspondance entre les identifiants des images et les lignes du CSV.
- Création d'un *manifeste* (fichier CSV récapitulatif) pour chaque image sélectionnée.
- Vérification manuelle de la pertinence de la sélection.

Data augmentation [4]

Afin d'enrichir le dataset et d'améliorer la robustesse des modèles :

- **Rotation** des images
- **Retournement** (flip horizontal/vertical)
- **Zoom** (changement d'échelle)
- Amélioration du **contraste et de la luminosité**

Arbre de décision de classification (GZD-5)




Figure 1 – GZD-5 (Walmsley et al. 2022). Ordre des questions posées aux volontaires.

Plan

- 1 Introduction et motivation
- 2 Le dataset : constitution et exemples
- 3 Approche Machine Learning**
- 4 Architectures des modèles Deep Learning
- 5 Entraînement
- 6 Résultats et évaluation
- 7 Conclusion

Pourquoi une baseline Machine Learning ?

Objectif

Avant de passer aux réseaux de neurones, nous établissons une **référence de performance** avec des méthodes classiques.

- Deux méthodes testées : **Arbre de décision** et **Forêt aléatoire (Random Forest)**.
- Classification à partir des pixels bruts des images.
- Séparation stratifiée : 80% entraînement / 20% test.
- Dataset : **14 982 images** (4 994 spirales, 4 995 elliptiques, 4 993 incertaines).


Arbre de décision — Résultats

Performances

- Accuracy entraînement : **95.43%**
 - Accuracy test : **55.79%**
- ⇒ Fort **overfitting**

Par classe (F1-score)

- Elliptique : 0.65
- Spirale : 0.59
- Incertaine : 0.42 (difficile)




Matrice de confusion — Decision Tree

Performances

- Accuracy test : **64.90%**
- Amélioration de +9 points vs Decision Tree.
- Réduction de l'overfitting par agrégation.

Par classe (précisions notables)

- Elliptique : **742** images correctes
- Spirale : **707** images correctes
- Incertaine : $F1 \approx 0.51$ (classe la plus difficile)



Matrice de confusion — Random Forest

Limites des méthodes classiques

- Les pixels sont traités **indépendamment** : aucune notion de structure spatiale.
- La classe **incertaine** reste systématiquement la plus difficile.
- Les méthodes classiques ne savent pas exploiter les caractéristiques visuelles globales.

Ce que nous en retenons

Modèle	Test Accuracy
Arbre de décision	55.79%
Random Forest	64.90%
Aléatoire (baseline)	$\approx 33\%$

⇒ Seuil de référence fixé. Les **réseaux de neurones convolutionnels** sont nécessaires.

Plan

- 1 Introduction et motivation
- 2 Le dataset : constitution et exemples
- 3 Approche Machine Learning
- 4 Architectures des modèles Deep Learning**
- 5 Entraînement
- 6 Résultats et évaluation
- 7 Conclusion

Quatre modèles de deep learning ont été construits et comparés :

Modèle	Architecture	Idée principale
1	Petit CNN	Réseau convolutionnel simple
2	VAE + Classifieur	Débruitage + espace latent
3	ResNet-18	Connexions résiduelles (18 couches)
4	ResNet-34	Connexions résiduelles (34 couches)


Modèle 1 — Petit réseau convolutionnel

Architecture

#	Couche	Dim.
1	Convolution	(3, 6, 5)
2	ReLU	—
3	Max Pooling	(2 × 2)
4	Fully Connected	(62 ² × 6, 3)

Objectif

Servir de **modèle de référence** simple, avant d'augmenter la complexité.



CNN simple

Modèle 2 — Variational Autoencoder (VAE)

Principe

Encoder les images dans un **espace latent** de faible dimension, puis reconstruire les images (débruitage). Le classifieur opère ensuite sur les représentations latentes.

Encodeur

#	Couche	Dim.
1	Conv2d	(3, 32, 3)
2	ReLU	—
3	Conv2d	(32, 64, 3)
4	ReLU	—
5	Conv2d	(64, 128, 3)
6	Flatten	128×16^2
7,8	FC (μ, σ^2)	$\rightarrow 64$

Décodeur

#	Couche	Dim.
1	FC	$64 \rightarrow 32768$
2	ConvTranspose2d	(128, 64, 4)
3	ReLU	—
4	ConvTranspose2d	(64, 32, 4)
5	ConvTranspose2d	(32, 3, 4)
6	Sigmoid	—

Modèle 2 — Fonction de perte du VAE

La perte totale combine deux termes :

Binary Cross-Entropy (reconstruction) :

$$\mathcal{L}_{\text{BCE}}(x, \hat{x}) = - \sum_{i=1}^n [x_i \log(\hat{x}_i) + (1 - x_i) \log(1 - \hat{x}_i)]$$

Divergence de Kullback-Leibler :

$$\mathcal{L}_{\text{KL}} = -\frac{1}{2} \sum_{j=1}^d [1 + \log(\sigma_j^2) - \mu_j^2 - \sigma_j^2]$$

Perte totale :


$$\mathcal{L}_{\text{VAE}} = \mathcal{L}_{\text{BCE}} + \beta \mathcal{L}_{\text{KL}}$$

Idée des réseaux résiduels (He et al., 2015)

Les **connexions résiduelles** (skip connections) contournent le problème de disparition du gradient dans les réseaux profonds.

#	Couche	Détail
1	Conv2d (7×7)	$3 \rightarrow 64$
2	BatchNorm + ReLU	—
3	MaxPool (3×3)	stride=2
4	2× ResBlock	$64 \rightarrow 64$
5	2× ResBlock	$64 \rightarrow 128$
6	2× ResBlock	$128 \rightarrow 256$
7	2× ResBlock	$256 \rightarrow 512$
8	AvgPool + FC	$512 \rightarrow 3$

Modèle 3 — ResNet-18



Extension de ResNet-18

Même principe, mais davantage de blocs résiduels : $3 + 4 + 6 + 3$ au lieu de $2 + 2 + 2 + 2$.

#	Couche	Détail
1	Conv2d (7×7) + BN + ReLU	$3 \rightarrow 64$
2	MaxPool (3×3 , stride=2)	—
3	$3 \times$ ResBlock	$64 \rightarrow 64$
4	$4 \times$ ResBlock	$64 \rightarrow 128$
5	$6 \times$ ResBlock	$128 \rightarrow 256$
6	$3 \times$ ResBlock	$256 \rightarrow 512$
7	AvgPool + FC	$512 \rightarrow 3$

Point à prendre en compte

Plus de profondeur $\neq$ meilleures performances avec un tel dataset (i.e. plutôt limité).

Plan

- 1 Introduction et motivation
- 2 Le dataset : constitution et exemples
- 3 Approche Machine Learning
- 4 Architectures des modèles Deep Learning
- 5 Entraînement**
- 6 Résultats et évaluation
- 7 Conclusion

Entraînement des modèles

Pour l'ensemble des modèles étudiés, nous utilisons une procédure d'entraînement similaire afin de comparer correctement les performances.

- séparation du dataset :
 - ▶ 80 % entraînement,
 - ▶ 20 % test ;
- entraînement sur CPU uniquement ;
- optimisation avec Adam ;
- maximum de 50 epochs selon les modèles ;
- utilisation de l'early stopping lorsque le modèle commence à overfit.

Fonction de perte

Pour les modèles de classification, nous utilisons la Cross-Entropy Loss, adaptée aux problèmes multi-classes.

Entraînement du VAE

Le Variational Autoencoder utilise une fonction de perte différente composée de deux termes :

- reconstruction de l'image ;
- régularisation de l'espace latent.

Binary Cross-Entropy :

$$\mathcal{L}_{BCE} = - \sum_{i=1}^n [x_i \log(\hat{x}_i) + (1 - x_i) \log(1 - \hat{x}_i)]$$

Divergence de Kullback-Leibler :

$$\mathcal{L}_{KL} = -\frac{1}{2} \sum_{j=1}^d (1 + \log(\sigma_j^2) - \mu_j^2 - \sigma_j^2)$$

Difficultés d'entraînement

Plusieurs difficultés apparaissent durant l'apprentissage des modèles :

- images bruitées et parfois floues ;
- faible résolution des galaxies ;
- dataset relativement limité pour des modèles profonds ;
- risque important d'overfitting ;
- temps d'entraînement élevé sur CPU.

Les solutions envisagées :

- data augmentation ;
- early stopping ;
- fine-tuning du learning rate ;
- modèles résiduels plus stables ;
- réduction du nombre d'epochs lorsque nécessaire.

Plan

- 1 Introduction et motivation
- 2 Le dataset : constitution et exemples
- 3 Approche Machine Learning
- 4 Architectures des modèles Deep Learning
- 5 Entraînement
- 6 Résultats et évaluation**
- 7 Conclusion

Résultats des modèles

Modèle	Train Acc.	Test Acc.	Loss
Decision Tree	95.43 %	55.79 %	–
Random Forest	–	64.90 %	–
Petit CNN	≈ 70 %	33.13 %	1.11
VAE + Classifier	≈ 44 %	44.00 %	–
ResNet-18	≈ 71 %	71.39 %	0.6226
ResNet-34	≈ 52 %	52.11 %	0.9934

- Les modèles classiques de machine learning obtiennent des résultats corrects mais restent limités pour le traitement direct d'images complexes.
- Le petit CNN souffre d'un fort problème de généralisation malgré une accuracy correcte sur l'entraînement.
- Le modèle basé sur le VAE améliore légèrement les performances mais reste insuffisant pour une classification robuste.
- Le modèle ResNet-18 obtient les meilleurs résultats avec une accuracy de **71.39 %**, grâce aux connexions résiduelles qui facilitent l'apprentissage.

- Les réseaux résiduels sont les architectures les plus adaptées à cette tâche.
- Le dataset reste relativement limité pour des modèles très profonds.
- La qualité des images influence fortement les performances :
 - ▶ bruit,
 - ▶ faible résolution,
 - ▶ objets difficiles à distinguer.
- L'early stopping permet de limiter l'overfitting sur ResNet-18.
- Les classes *uncertain* restent les plus difficiles à classifier.

Plan

- 1 Introduction et motivation
- 2 Le dataset : constitution et exemples
- 3 Approche Machine Learning
- 4 Architectures des modèles Deep Learning
- 5 Entraînement
- 6 Résultats et évaluation
- 7 Conclusion**

Conclusion

- Ce projet avait pour objectif de classer automatiquement des galaxies à partir d'images du dataset Galaxy Zoo.
- Nous avons comparé plusieurs approches :
 - ▶ machine learning classique,
 - ▶ réseaux convolutionnels,
 - ▶ Variational Autoencoder,
 - ▶ réseaux résiduels.
- Les résultats montrent que le modèle ResNet-18 constitue le meilleur compromis entre :
 - ▶ performance,
 - ▶ capacité de généralisation,
 - ▶ coût computationnel.
- Ce projet met également en évidence l'importance :
 - ▶ du pré-traitement des données,
 - ▶ de la qualité du dataset,
 - ▶ du choix de l'architecture,
 - ▶ de la gestion de l'overfitting.

Plusieurs améliorations pourraient être envisagées :

- utilisation d'un dataset plus grand ;
- amélioration du data augmentation ;
- débruitage plus avancé des images ;
- entraînement sur GPU ;
- transfer learning avec des modèles pré-entraînés ;
- architectures plus récentes :
 - ▶ EfficientNet,
 - ▶ Vision Transformers,
 - ▶ modèles hybrides CNN/Transformer.
- amélioration spécifique de la classification de la classe *uncertain*.

Questions ?

Références

-  Galaxy Zoo, 2007. *Premier échantillon de données, collectées par des volontaires.*
-  Willett et al., Galaxy Zoo 2, 2013.
-  A. Guruprasad. *Galaxy classification : a machine learning approach.* 2023.
-  A. Spindler, L. H. Butterworth. *The effects of image augmentations when training ML models in astronomy.* 2026.
-  S. S. Mirzoyan. *Enhancing galaxy classification with U-Net VAE for image denoising.* Juin 2025.
-  Liu, Ling Zhang, Han. *A multi-modal fusion network for star-galaxy classification from CSST simulated datasets.* Avril 2026.